



Active Learning en Sistemas Recomendadores

Denis Parra

IIC3633 – Sistemas Recomendadores

PUC Chile

Active Learning en Sistemas Recomendadores

Referencias

- Slides basadas principalmente en:

Mehdi Elahi, Francesco Ricci, Neil Rubens, A survey of active learning in collaborative filtering recommender systems,

Computer Science Review, Volume 20, May 2016, Pages 29-50, ISSN 1574-0137,

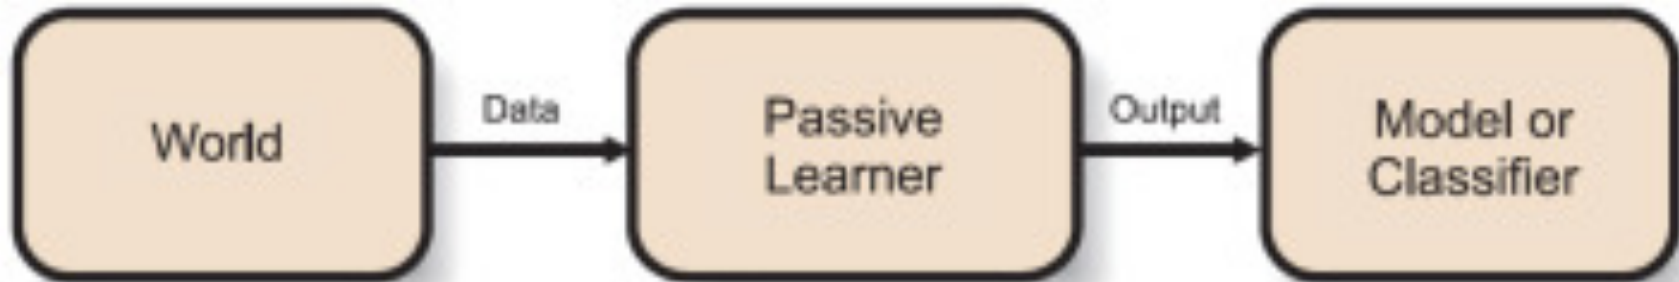
<http://dx.doi.org/10.1016/j.cosrev.2016.05.002>.

(<http://www.sciencedirect.com/science/article/pii/S1574013715300150>)

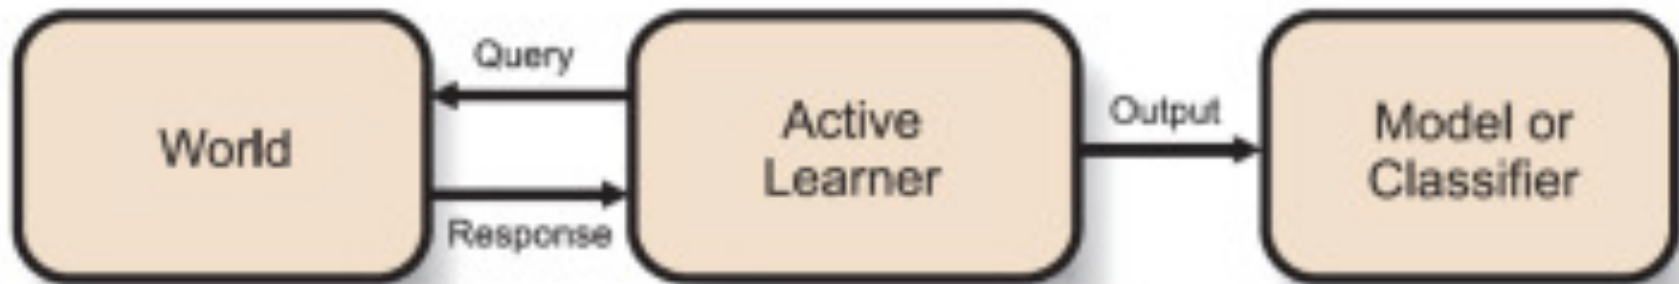
El Problema de Recomendación

- ... hasta ahora, es predecir ratings or rankear items dado un dataset existente
- Sin embargo, los sistemas evolucionan de forma dinámica
- Una estrategia de Aprendizaje Activo en Filtrado Colaborativo implica una estrategia precisa para seleccionar items de forma que el usuario provea ratings y eso nos permita mejorar nuestro sistema.

Active Learning



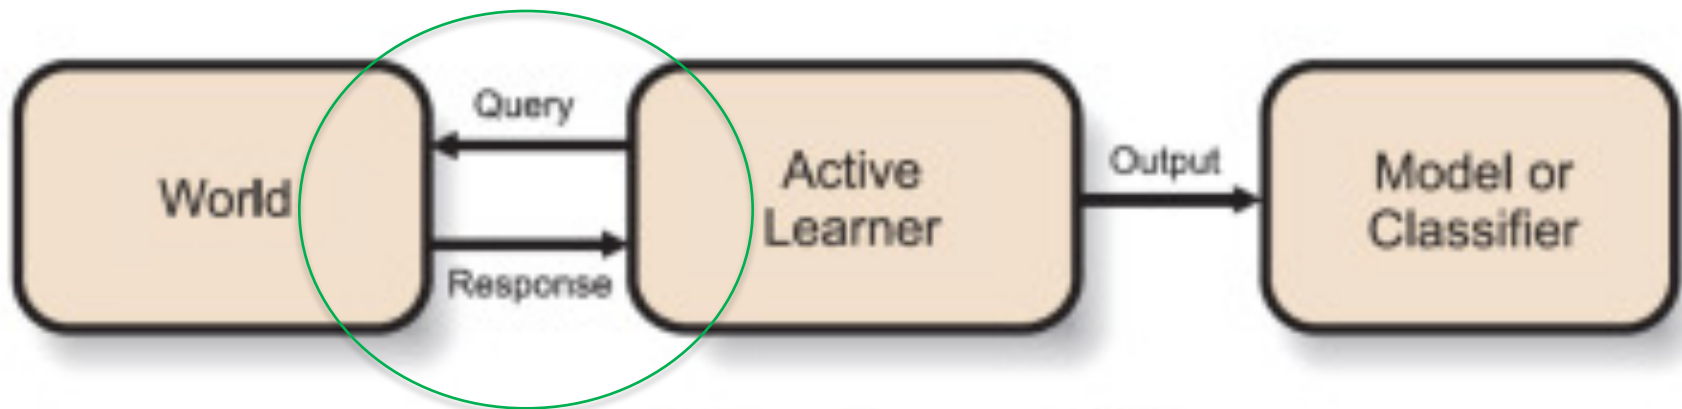
General schema for a passive learner.



General schema for an active learner.

Active Learning

... el proceso de guiar el muestreo de datos a través de la consulta de ciertos tipos de instancias basado en los datos que el sistema ha visto hasta el momento.



General schema for an active learner.

Algoritmo Genérico

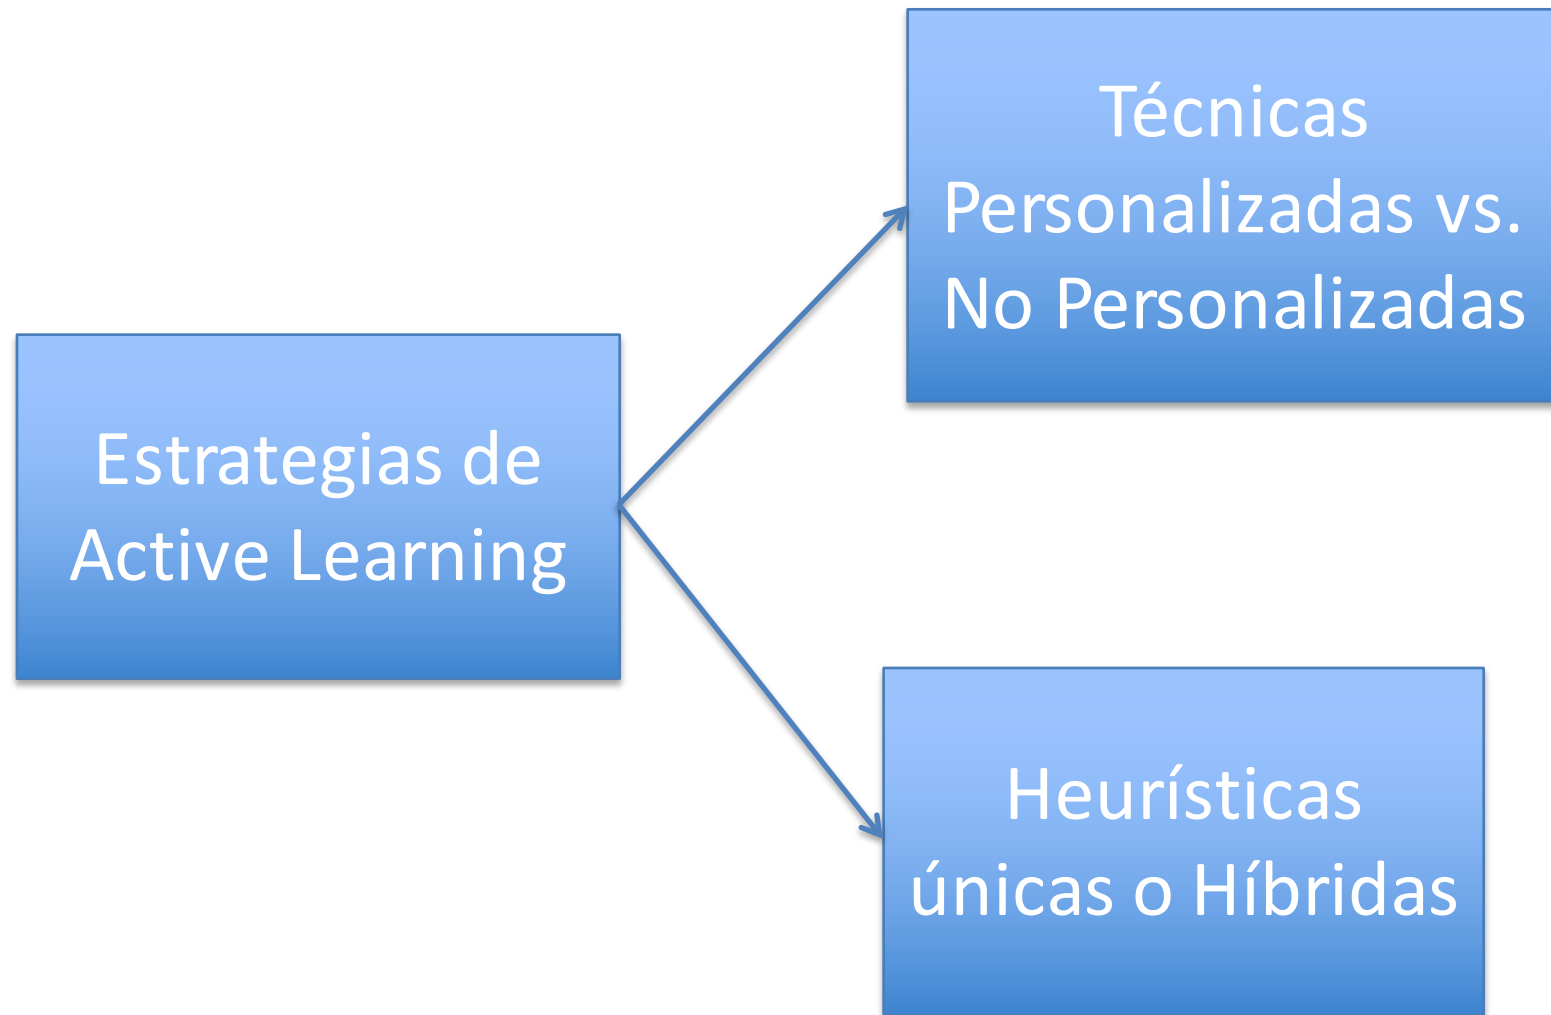
```
for  $j:=1$  to  $totalIterations$  do  
  foreach  $q_j$  in  $potentialQueries$  do  
    Evaluate  $Loss(q_j)$ ;  
  end  
  Ask query  $q_j$  for which  $Loss(q_j)$  is the lowest;  
  Update model  $\mathcal{M}$  with query  $q_j$  and response  $(q_j, y_j)$ ;  
end  
return model  $\mathcal{M}$ ;
```

Algorithm 1: General algorithm for Active Learning [58]

A.L. en el problema de Recomendación

- New User
- New Item
- Costo de Obtener Feedback
- Adaptación de métodos de Aprendizaje Activo

Clasificación de Técnicas Existentes



Técnicas Personalizadas/No Personalizadas

- **No Personalizadas:** Solicitar a los usuario dar feedback (ratings) a los mismos ítems. Esto podría ayudar a mejorar el sistema en general pero quizás en detrimento de preferencias de usuarios específicos.
- **Personalizadas:** Seleccionar los items considerando los gustos o preferencias del usuario, o que permitan de forma más efectiva obtener esta información.

Herísticas únicas o Híbridizadas

- **Single-Heuristic:** Se considera sólo una regla de selección, la cual se utiliza para seleccionar items.
- **Combined-Heuristic:** Permiten contribuir una estrategia Híbrida al agregar o combinar varias opciones con potencial de mejorar el rendimiento del sistema y, por ende, ser usadas para ratings de usuarios.

Ejemplo Ilustrativo

- ¿Qué película nos conviene escoger?

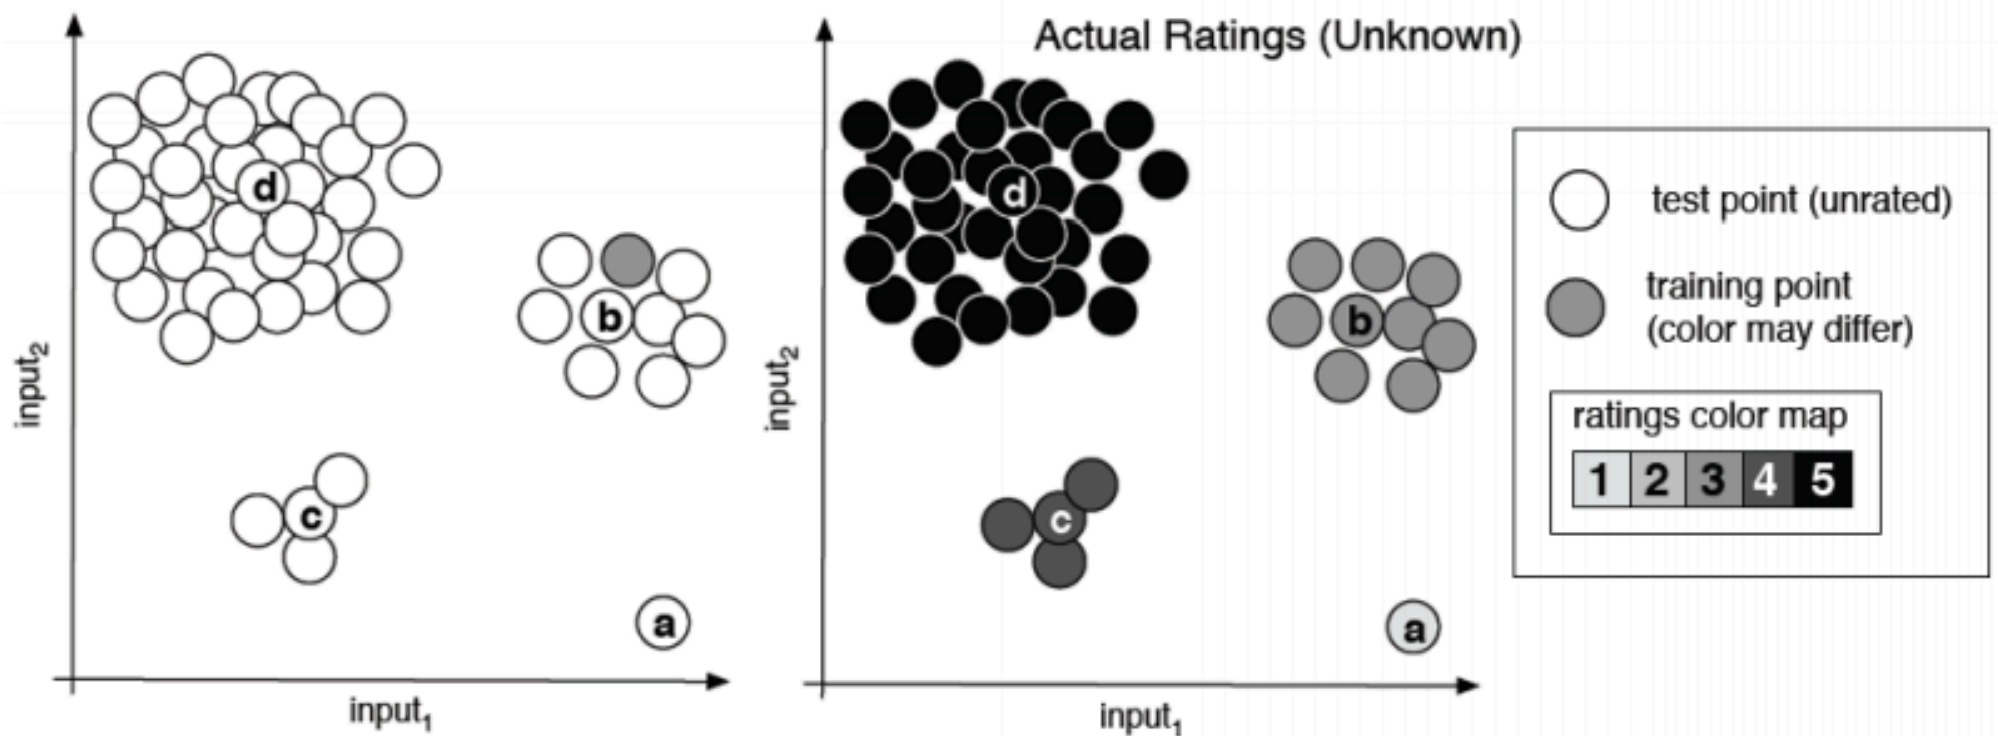
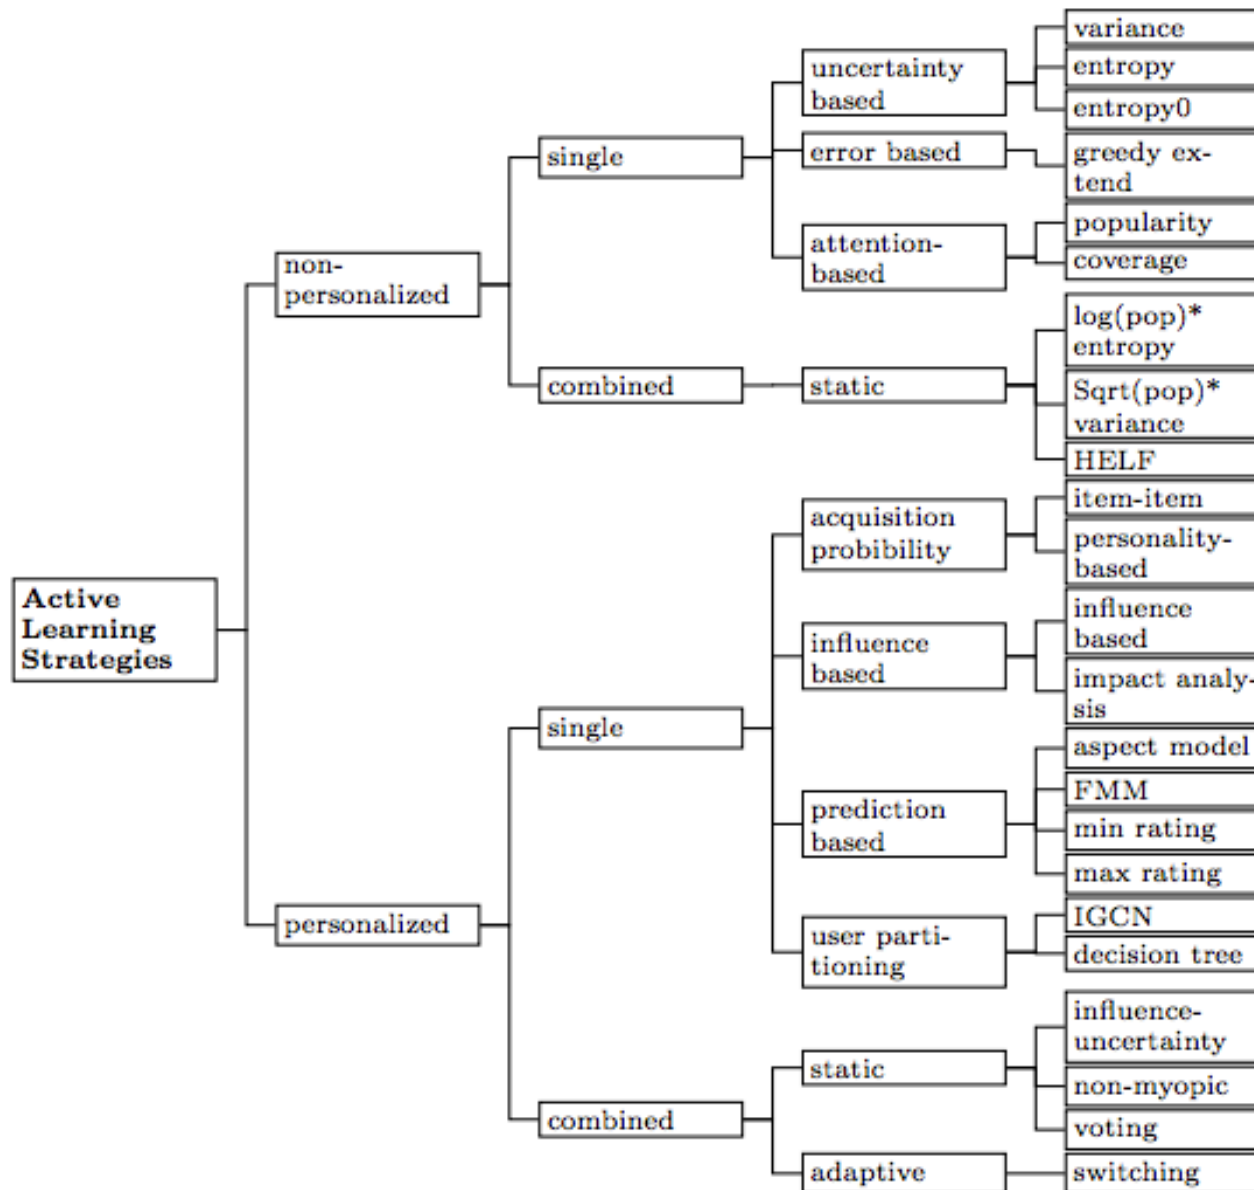


Fig. 1. Active learning, an illustrative example [19]

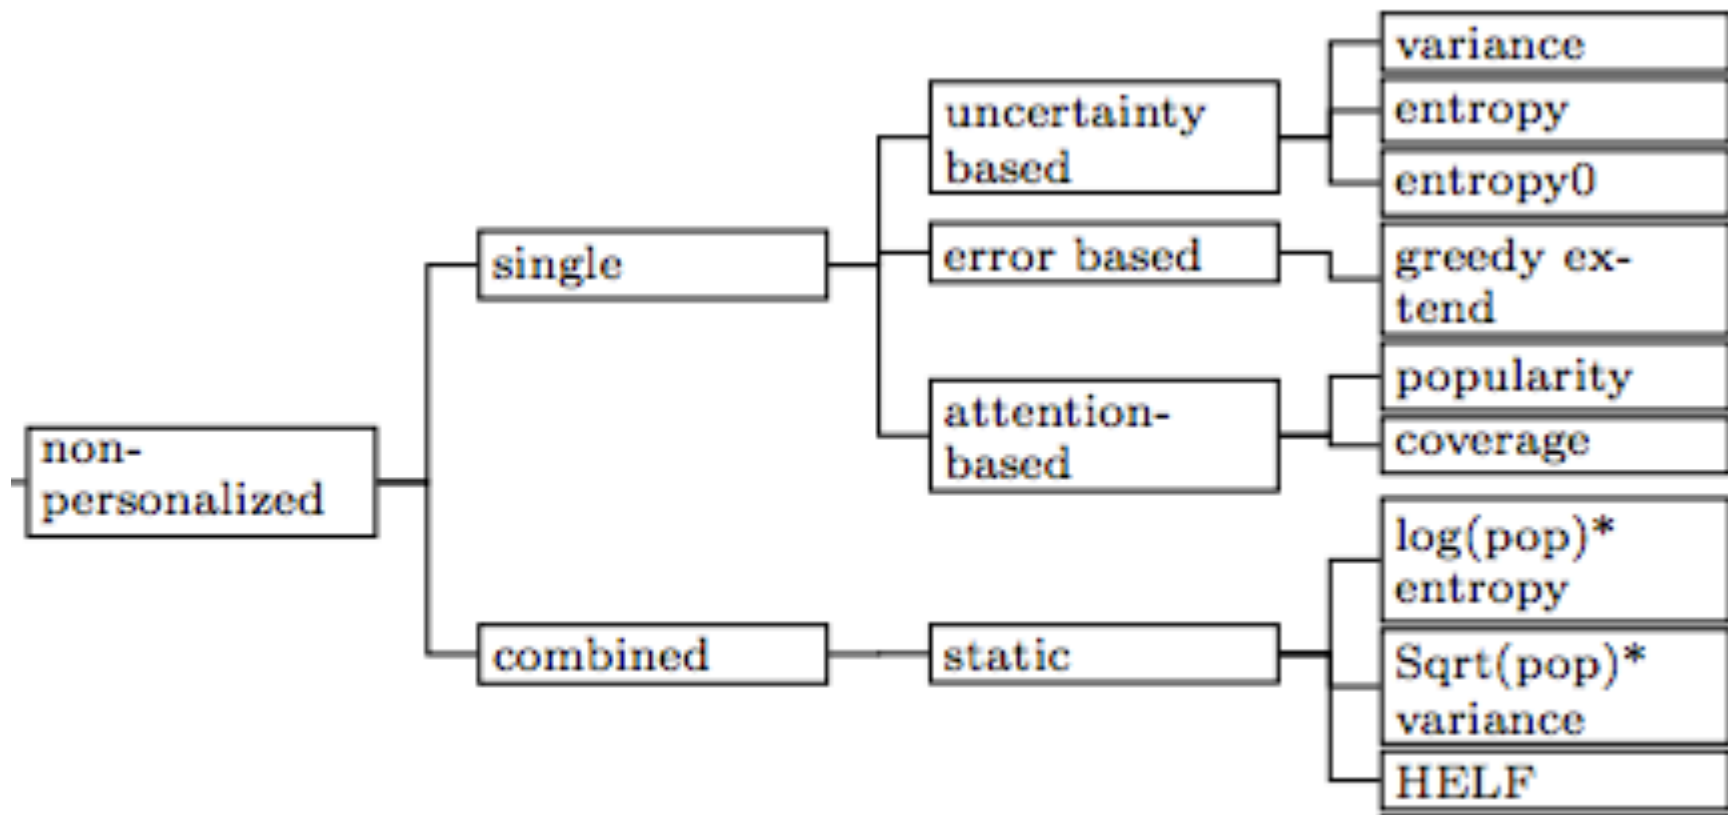
Propiedades de los Datos

- (R1) Representado (e.g. Trilogía Star Wars, disminuir redundancia)
- (R2) Representativo (e.g. elegir items que representen tipos generales: Drama mejor que Zombie)
- (R3) Resultados: Elegir este punto mejorará mi predicción o algún otro objetivo?

Jerarquía de Estrategias



Non-Personalized (Several Heuristics)



Aprendizaje Activo No-Personalizado

- Estrategias de Heurística única
 - Basadas en Reducción de Incerteza
 - Basadas en Reducción del Error
 - Basadas en Atención

Estrategias Basadas en Red. Incerteza

- Varianza

$$\text{Variance}(i) = \frac{1}{|U_i|} \sum_{u \in U_i} (r_{ui} - \bar{r}_i)^2$$

- Entropía y Entropía0

$$H = - \sum p(x) \log p(x)$$

- Entropía0 asigna el valor “0” a ratings no observados. ¿Por qué?

Estrategias Basadas en Red. Incerteza

- Varianza: seleccionar items con alta varianza

$$\text{Variance}(i) = \frac{1}{|U_i|} \sum_{u \in U_i} (r_{ui} - \bar{r}_i)^2$$

- Entropía y Entropía0

$$H = - \sum p(x) \log p(x)$$

- Entropía0 asigna el valor “0” a ratings no observados. ¿Por qué? Entropía favorece a items “oscuros” y con pocos ratings.

Ratings y Entropía


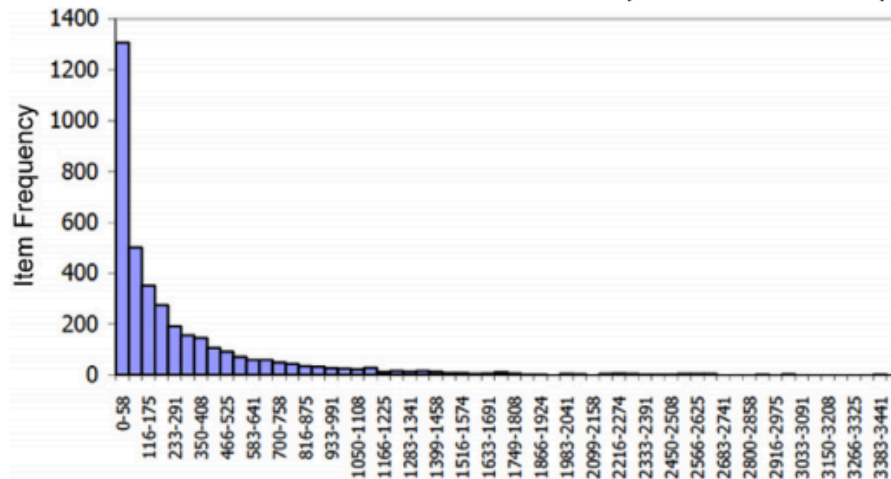



Fig. 6 – (a) Correlation between the entropy and popularity of the items (Movielens dataset) [68].



(a) Popularity.



(b) Entropy.

Fig. 5 – (a) Distribution of the popularity of the items, and (b) distribution of the entropy of the items (Movielens dataset) [68].

Estrategias Basadas en Error

- Mejorar directamente la exactitud de predicción del sistema.
- Greedy Extend (Golbandi et al. 2010): Identifica directamente el set de items que reducen el error (e.g. RMSE)

$$L_u = \operatorname{argmin}_{L \subset I_u} F(A(L))$$

- A: Algoritmo de predicción
- $F(A(L))$: Función de error
- I_u : items a los cuales “u” puede dar ratings

Estrategias Basadas en Error

- Greedy Extend (Golbandi et al. 2010):
Identifica directamente el set de items que reducen el error (e.g. RMSE)

$$L_u = \operatorname{argmin}_{L \subset I_u} F(A(L))$$

- El algoritmo funciona calculando RMSE antes y después de agregar el rating de un ítem.
- **Se selecciona en ítem con mayor reducción de error.**

Estrategias Basadas en Error II

- Mejorar directamente la exactitud de predicción del sistema.
- Basadas en representatividad: Pedir al usuario que de ratings sobre items que pueden reconstruir mejor la matriz de ratings R

$$R \approx CX \quad \text{minimize } \|R - CX\|^2$$

- Donde C es un subconjunto de las columnas de R (ítems), y X es una matriz de parametros.

Estrategias Basadas en Atención

- Items que han recibido la mayor atención
- Fáciles de implementar, propuestas iniciales para resolver el cold-start
 - Popularidad: Elegir ítems que han recibido la mayor cantidad de items.
 - Co-coverage: Elegir ítems que han sido co-rated por muchos usuarios.

$$\text{Co-coverage}(i) = \sum_{j=1}^n m_{ij}$$

m_{ij} : nro. de usuarios que co-rated
ítems i y j

Estrategias Basadas en Atención II

- Items que han recibido la mayor atención
- Fáciles de implementar, propuestas iniciales para resolver el cold-start
 - Popularidad: Elegir items que han recibido la mayor cantidad de items.
 - Co-coverage: Elegir items que han sido co-rated por muchos usuarios.
- Ambas métricas tienen el problema de **pre-fix bias**, recomendaciones irán a ítems más populares.

Aprendizaje Activo No-Personalizado


- Estrategias de Heurística Combinada (Estáticas)
 - Random Popularity
 - $\text{Log}(\text{pop}) * \text{entropy}$
 - $\text{SQRT}(\text{pop}) * \text{entropy}$
 - HELF

Random Popularity

- Incluir elementos populares en una lista de items random, para aumentar la chance de que el usuario haya consumido el ítem y así pueda darle ratings.
- Se usó este método en estudio de movielens para elicitare ratings de usuarios nuevos en el sistema. Aspecto principal : familiaridad.
- También se le llama *Classique* a esta técnica.

$F(\text{pop}) * \text{entropy}$

- $\text{Log}(\text{pop}) * \text{entropy}$: Intenta combinar el efecto de popularidad con la entropía de los ratings
- $\text{Sqrt}(\text{pop}) * \text{entropy}$: Variación usa raíz cuadrada en lugar de $\log()$ y en algunos casos, varianza en lugar de entropía.



HELF

- Harmonic Mean de Entropía y Logaritmo de la Frecuencia
- Combina popularidad con “informativeness”. Funciona bien porque la entropía tiende a seleccionar items que rara vez han sido “rated”.

$$HELF(i) = \frac{2 \times LF_i \times H(i)}{LF_i + H(i)}$$

Comparación

- Basada en paper “On Bootstrapping Recommender Systems” de Golbandi et al. (2010)


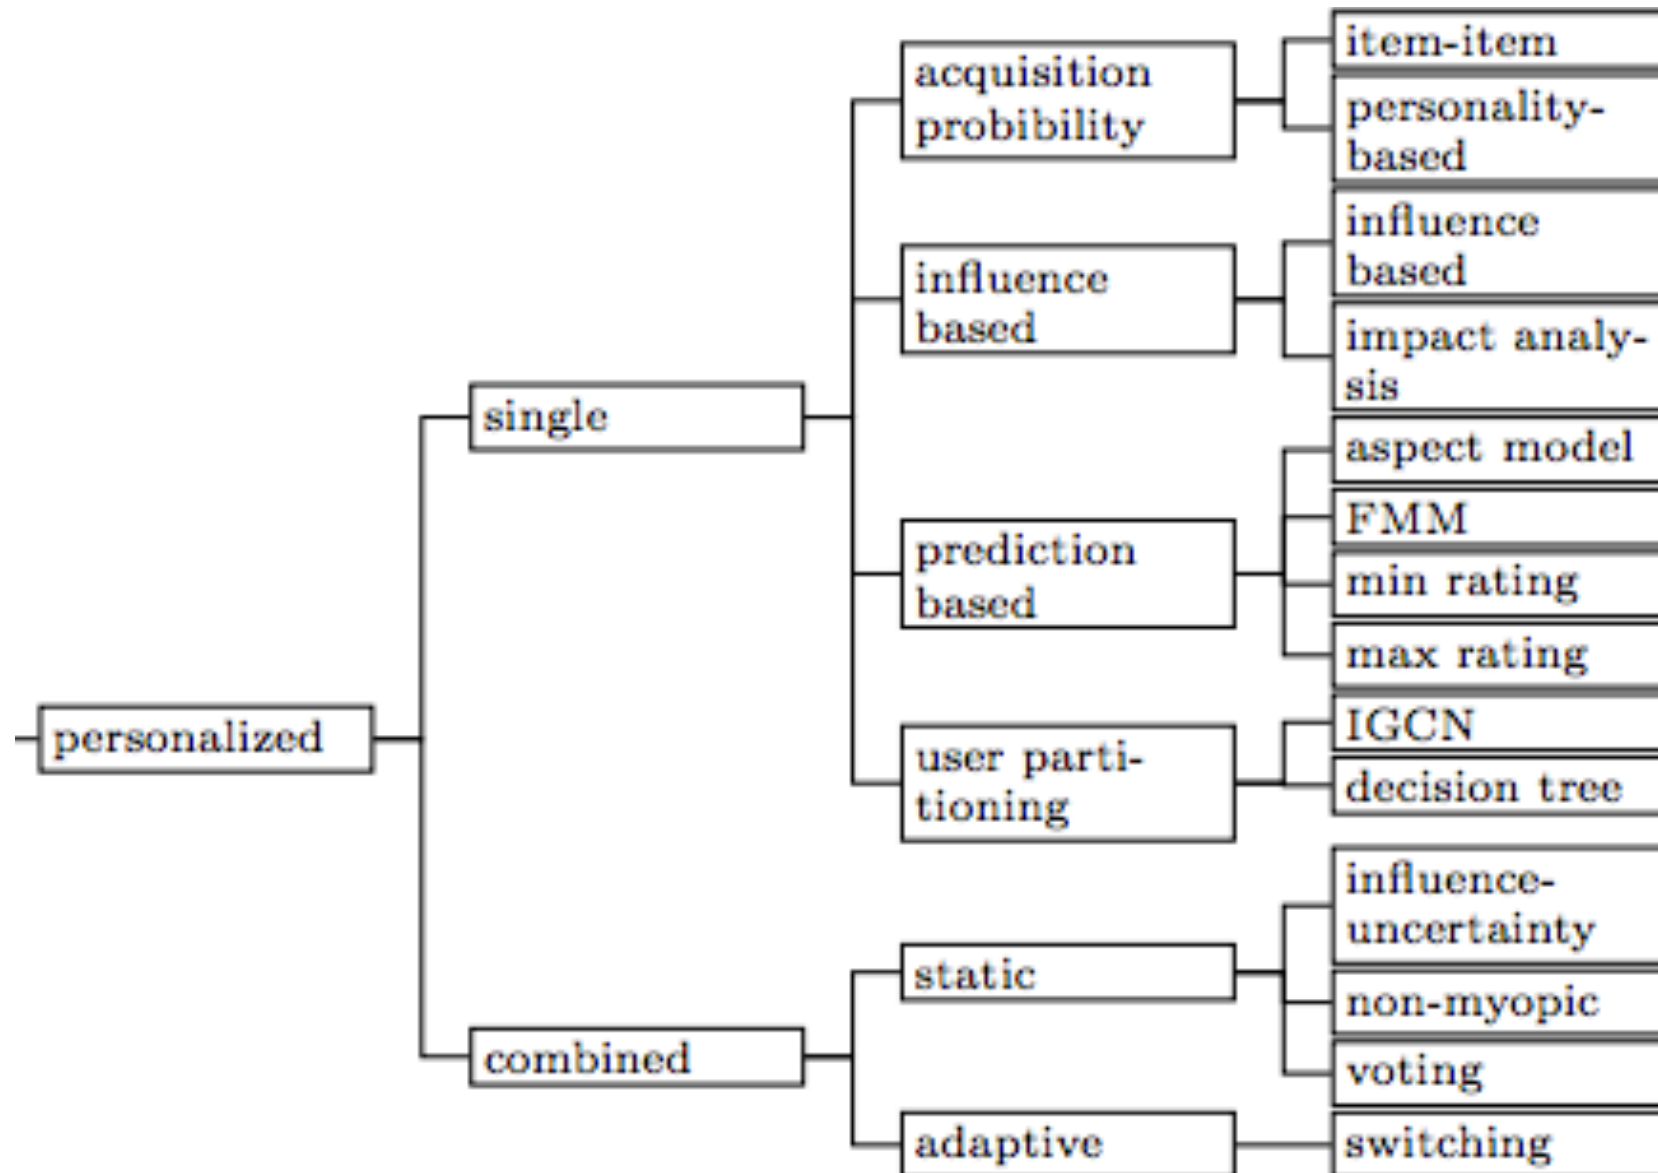


Figure 2: The test error rate vs. number of displayed items (=size of seed set), for various methods of selecting seed set items. Methods that disregard item popularity (Random and Entropy) significantly lag in performance. GreedyExtend delivers the best performing seed sets by guiding the set creation process with a suitable cost function. Note that the legend orders methods by their performance.

Aprendizaje Activo Personalizado

- Estrategias de Heurística única
 - Probabilidad de Adquisición
 - Basadas en Impacto
 - Basadas en Predicción
 - Particionamiento de los Usuarios

Personalized (Several Heuristics)



Probabilidad de Adquisición

- Estrategia Item-Item: Seleccionar ítems más similares a los ítems que el usuario ya evaluó

$$\text{sim}(i, j) = \frac{\sum_{u \in U_{ij}} (r_{ui} - \bar{r}_i)(r_{uj} - \bar{r}_j)}{\sqrt{\sum_{u \in U_{ij}} (r_{ui} - \bar{r}_i)^2 \sum_{u \in U_{ij}} (r_{uj} - \bar{r}_j)^2}}$$

- Predicción Binaria: Intenta identificar los items que el usuario más probablemente hubiese consumido/evaluado. Transforma matriz de ratings en 1/0 y se predice un score para los items con $r_{ui} = 0$.

Probabilidad de Adquisición

- Predicción Binaria basada en personalidad: Intenta identificar los items que el usuario más probablemente hubiese consumido/evaluado, considera características del usuario como Personalidad.

$$\hat{s}_{ui} = \bar{i} + b_u + q_i^\top \left(p_u + \sum_{a \in A(u)} y_a \right)$$

Basadas en Impacto

- Seleccionan ítems con la intención de minimizar la incerteza de predicción para todos los ítems, no necesariamente el error final.
 - Basada Directamente en Influencia: Calculamos r_{ui} y $r_{ui}' = r_{ui} - 1$, observamos el impacto en la predicción de otros ítems usando ambos.
 - Análisis de Impacto: Basado en análisis del grafo bipartito

Basadas en Impacto II

- Análisis de Impacto: Basado en análisis del grafo bipartito. Busca qué ratings (enlaces) pueden producir más "four-node paths"




Fig. 7 – Simple Bipartite Graph Model for CF [75].

Basada en Predicción

- Se predican ítems con modelos tradicionales, los ítems predichos con mayor rating se presentan a los usuarios:
 - Modelo de Aspecto: relacionado con topic models o “aspectos”

$$p(r|u, i) = \sum_{z \in Z} p(r|z, i)p(z|u)$$

- Highest Predicted / Lowest Predicted
- MinNorm: Hacer factorización matricial y elegir los ítems con menor norma en sus vectores latentes.

Particionamiento de los Usuarios

- IGCN: Information Gain a través de clustering de los vecinos. Consiste en construir un árbol de decisión donde los nodos son items y las hojas son clusters de usuarios.
- Árbol de Decisión: Similar al anterior, pero más específico. Dado un ítem o grupo de ítems, se separan 3 grupos: Lovers, Haters y Unknowns. Se hacen predicciones para cada grupo, sobre los items no evaluados aún.

Aprendizaje Activo Personalizado

- Estrategias de Heurística Combinada
 - Combinación Estática
 - Influencia-Incerteza
 - No miópica
 - Decision Tree-MF
 - Functional MF
 - Votación
 - Adaptativas
 - Switching

Influencia-Incerteza

- Combina 2 estrategias: influencia y varianza

$$\operatorname{argmax}_i \operatorname{Var}(i) I(i)$$

- Donde $I(i)$ es la influencia del item i sobre el resto del dataset.

No miópica

- Combina 2 estrategias: minRated y minNorm

$$\text{score}(i) = (1 - w) \text{minRating_rank}(i) + w \text{minNorm_rank}(i)$$

$$w = \frac{\text{\#current_request} - 1}{\text{\#total_request}}$$

- Donde #current_request es el número de veces que el usuario ha sido solicitado por rating, y #total_request el total esperado.

Resumen

Table 1 – Performance comparison of active learning strategies (“✓✓” Very Good, “✓” Good, “x” Poor, “–” Not Available) ML: MovieLens, NF: Netflix, EM: EachMovie, AWM: Active Web Museum, MP: MyPersonality, STS: South Tyrol Suggests, LF: Last.fm.

	Type	Strategy	Metric				Eval.		Compar. Strategies	Datasets
			MAE/ RMSE	NDCG/ MAP	Precision	# Rating	Online	Offline		
Non-personalized	Single	1. Variance [59,61]	✓	–	–	–	–	y	2, 4, 6, 9, 24	AWM, EM
		2. Entropy [20,68]	x	–	–	–	–	y	3, 6, 8, 9, 11,13, 22	EM
		3. Entropy0 [68]	✓✓	–	–	✓✓	y	y	2, 6, 8, 11, 13, 22	ML
	Error reduction	4. Greedy extend [69]	✓	–	–	–	–	y	2, 3, 6, 7, 10, 11	NF
		5. Representative [70]	–	✓✓	✓✓	–	–	y	6	NF, ML, LF
	Attention based	6. Popularity [20,68]	✓	–	–	✓✓	y	y	2,8, 9, 11, 13, 22	ML
		7. Co-coverage [69]	x	–	–	–	–	y	2, 3, 4, 6, 10, 11	NF
	Combined	8. Rand-pop [20,68]	x	–	–	x	y	y	2, 3, 6, 11, 13, 22	ML
		9. Log(pop)*entropy [20]	✓✓	–	–	✓	y	y	3,6, 8, 13	ML
		10. sqrt(pop)*var [69]	✓	–	–	–	–	y	2, 3, 4, 6, 7, 11	NF
		11. HELF [68]	✓✓	–	–	x	y	y	2, 3,6, 8, 13, 22	ML
		12. Non-pers-part rand. [11]	✓	✓✓	✓	x	–	y	1, 6, 9, 12, 14, 20, 21, 28,29	ML, NF
		13. Item-item [20,68]	x	–	–	✓✓	y	y	2, 3, 6, 8, 9, 11, 22	ML
	Acquisition prob.	14. Binary-pred [11,12]	✓	x	✓✓	✓	–	y	1, 6, 9, 12, 20, 21, 28, 29	ML, NF
		15. Personality-based [77,97]	✓✓	✓✓	–	✓✓	y	y	3, 9, 14	STS, MP
		16. Impact analysis [75]	✓✓	–	–	–	–	y	9	ML
		17. Aspect model [83,84]	✓	–	–	–	–	y	2	EM, ML
Personalized	Single	18. Min rating [76]	✓	–	–	–	–	y	19,25	ML
		19. Min norm [76]	x	–	–	–	–	y	18,25	ML
		20. Highest-pred [11,12]	✓	x	✓✓	✓	–	y	1, 6, 9, 12, 14, 21, 28,29	ML, NF
		21. Lowest-pred [11,12]	✓	x	✓	x	–	y	1, 6, 9, 12, 14, 20, 28, 29	ML, NF
		22. IGCN [68]	✓✓	–	–	✓	y	y	2, 3,6, 8, 11, 13	ML
	User partitioning	23. Decision tree [64]	✓✓	–	–	–	–	y	3, 4, 10, 11	NF
		24. Influence based [61]	✓✓	–	–	–	–	y	1, 4, 6, 9	ML
		25. Non-myopic [76]	✓	–	–	–	–	y	18, 19	ML
	Static combin.	26. TreeU [90]	✓	–	–	–	–	y	23, 27	ML, EM, NF
		27. fMF [90]	✓✓	–	–	–	–	y	23,26	ML, EM, NF
		28. Pers-partially rand. [11]	✓	✓✓	✓	x	–	y	1, 6, 9, 12, 14, 20, 21, 28,29	ML, NF
	Adaptive combin.	29. Voting [11,12]	✓✓	✓✓	x	x	–	y	1, 6, 9, 12,14, 20, 21, 28	ML, NF
		30. Switching [91]	✓✓	✓✓	–	✓✓	–	y	9, 20, 29	ML

Resumen

- Elicitar sólo items con ratings altos produce sesgo en el modelo y las predicciones
- Aleatorización parcial puede ser beneficiosa
- Personalización incrementa la chance de que los usuarios provean ratings
- Explotar información adicional (personalidad, información de la red) puede también ser beneficioso